

# Inferencia para la normal multivariada, Parte II

**Graciela Boente**

## Estadístico $U$ de Rao

Sean  $\mathbf{y} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$  con  $\boldsymbol{\Sigma} > 0$  y  $\mathbf{W} \sim \mathcal{W}(\boldsymbol{\Sigma}, p, m)$  independientes entre sí,  $m \geq p$ .

Particionemos a  $\mathbf{y}$ ,  $\boldsymbol{\mu}$ ,  $\boldsymbol{\Sigma}$  y  $\mathbf{W}$  de la siguiente forma

$$\mathbf{y} = \begin{pmatrix} \mathbf{y}^{(1)} \\ \mathbf{y}^{(2)} \end{pmatrix}$$

$$\boldsymbol{\mu} = \begin{pmatrix} \boldsymbol{\mu}^{(1)} \\ \boldsymbol{\mu}^{(2)} \end{pmatrix}$$

$$\boldsymbol{\Sigma} = \begin{pmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{pmatrix}$$

$$\mathbf{W} = \begin{pmatrix} \mathbf{W}_{11} & \mathbf{W}_{12} \\ \mathbf{W}_{21} & \mathbf{W}_{22} \end{pmatrix}$$

con  $\mathbf{y}^{(i)}, \boldsymbol{\mu}^{(i)} \in \mathbb{R}^{p_i}$ ,  $\boldsymbol{\Sigma}_{ij} \in \mathbb{R}^{p_i \times p_j}$ ,  $\mathbf{W}_{ij} \in \mathbb{R}^{p_i \times p_j}$ ,  $p_1 + p_2 = p$ .



## Estadístico $U$ de Rao

Usando que

$$\Sigma^{-1} = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix}^{-1} = \begin{pmatrix} \Sigma_{11}^{-1} + \beta^T \Sigma_{22.1}^{-1} \beta & -\beta^T \Sigma_{22.1}^{-1} \\ -\Sigma_{22.1}^{-1} \beta & \Sigma_{22.1}^{-1} \end{pmatrix}$$

con

$$\beta = \Sigma_{21} \Sigma_{11}^{-1} \in \mathbb{R}^{p_2 \times p_1}$$

es fácil ver que

$$\lambda_p^2 - \lambda_{p_1}^2 = \mu_{2.1}^T \Sigma_{22.1}^{-1} \mu_{2.1}$$

con

$$\mu_{2.1} = \mu^{(2)} - \beta \mu^{(1)}$$

$$\Sigma_{22.1} = \Sigma_{22} - \Sigma_{21} \Sigma_{11}^{-1} \Sigma_{12}$$

Nos interesará testear  $H_0 : \lambda_p^2 = \lambda_{p_1}^2$  que es equivalente a  $\mu_{2.1} = 0$ .

Observemos que como

$$\lambda_p^2 - \lambda_{p_1}^2 = \mu_{2.1}^T \Sigma_{22.1}^{-1} \mu_{2.1}$$

y

$$\mu_{2.1} = \mu^{(2)} - \beta \mu^{(1)} \quad \beta = \Sigma_{21} \Sigma_{11}^{-1}$$

- $H_0$  equivale a  $\mu^{(2)} = 0$  si  $\mu^{(1)} = 0$
- $H_0$  equivale a  $\mu^{(2)} = 0$  si  $\mathbf{y}^{(1)}$  y  $\mathbf{y}^{(2)}$  son independientes, o sea, si  $\Sigma_{12} = \mathbf{0}$

## Estadístico $U$ de Rao

Para testear  $H_0$ , nos basaremos en

$$T_{p,m}^2 - T_{p_1,m}^2 = m \mathbf{y}_{2.1}^T \mathbf{W}_{22.1}^{-1} \mathbf{y}_{2.1}$$

donde

$$\mathbf{y}_{2.1} = \mathbf{y}^{(2)} - \mathbf{B}\mathbf{y}^{(1)} \quad \mathbf{B} = \mathbf{W}_{21}\mathbf{W}_{11}^{-1} \in \mathbb{R}^{p_2 \times p_1}$$

$$\mathbf{W}_{22.1} = \mathbf{W}_{22} - \mathbf{W}_{21}\mathbf{W}_{11}^{-1}\mathbf{W}_{12}$$

El estadístico  $U$ -de Rao se define por

$$U = \left\{ 1 + \frac{T_{p_1,m}^2}{m} \right\} \left\{ 1 + \frac{T_{p,m}^2}{m} \right\}^{-1}$$

Como

$$\frac{T_{p,m}^2 - T_{p_1,m}^2}{m + T_{p_1,m}^2} = \frac{1}{U} - 1$$

Rechazaremos  $H_0$  si  $T_{p,m}^2 - T_{p_1,m}^2$  es grande o sea si  $U$  es chico.

## Lema 1

Sea  $\mathbf{W} \sim \mathcal{W}(\boldsymbol{\Sigma}, p, m)$  con  $m \geq p$  y  $\boldsymbol{\Sigma} > 0$ .

- a)  $\mathbf{W}_{22.1} \sim \mathcal{W}(\boldsymbol{\Sigma}_{22.1}, p - p_1, m - p_1)$ .
- b)  $\mathbf{W}_{22.1}$  es independiente de  $(\mathbf{W}_{11}, \mathbf{W}_{12})$  y por lo tanto de  $\mathbf{B}$ .
- c) La distribución condicional de  $\mathbf{W}_{12}$  dado  $\mathbf{W}_{11} = \mathbf{w}_{11}$  es

$$\mathbf{W}_{12} \Big|_{\mathbf{W}_{11} = \mathbf{w}_{11}} \sim N(\mathbf{w}_{11} \boldsymbol{\Sigma}_{11}^{-1} \boldsymbol{\Sigma}_{12}, \mathbf{w}_{11} \otimes \boldsymbol{\Sigma}_{22.1})$$

y la de  $\mathbf{W}_{21}$  dado  $\mathbf{W}_{11} = \mathbf{w}_{11}$  es

$$\mathbf{W}_{21} \Big|_{\mathbf{W}_{11} = \mathbf{w}_{11}} \sim N(\boldsymbol{\Sigma}_{21} \boldsymbol{\Sigma}_{11}^{-1} \mathbf{w}_{11}, \boldsymbol{\Sigma}_{22.1} \otimes \mathbf{w}_{11})$$

de donde la distribución condicional de  $\mathbf{B} = \mathbf{W}_{21} \mathbf{W}_{11}^{-1}$  dado  $\mathbf{W}_{11} = \mathbf{w}_{11}$  es

$$\mathbf{B} \Big|_{\mathbf{W}_{11} = \mathbf{w}_{11}} \sim N(\boldsymbol{\Sigma}_{21} \boldsymbol{\Sigma}_{11}^{-1}, \boldsymbol{\Sigma}_{22.1} \otimes \mathbf{w}_{11}^{-1})$$

## Corolario 1

Sea  $\mathbf{W} \sim \mathcal{W}(\mathbf{\Sigma}, p, m)$  con  $m \geq p$  y  $\mathbf{\Sigma} > 0$  y definamos

$$\mathbf{A} = \mathbf{W}_{21} \mathbf{W}_{11}^{-1} \mathbf{W}_{12} \in \mathbb{R}^{(p-p_1) \times (p-p_1)}.$$

Entonces, si  $\mathbf{\Sigma}_{12} = \mathbf{0}$ , se cumple que

- $\mathbf{A} \sim \mathcal{W}(\mathbf{\Sigma}_{22}, p - p_1, p_1)$  y
- $\mathbf{A}$  es independiente de  $\mathbf{W}_{22.1}$  y  
 $\mathbf{W}_{22.1} \sim \mathcal{W}(\mathbf{\Sigma}_{22.1}, p - p_1, m - p_1) = \mathcal{W}(\mathbf{\Sigma}_{22}, p - p_1, m - p_1)$



## Corolario 2

Sea  $\mathbf{W} \sim \mathcal{W}(\boldsymbol{\Sigma}, p, m)$  con  $m \geq p$  y  $\boldsymbol{\Sigma} > 0$  y definamos

$$\mathbf{A} = \mathbf{W}_{12} \mathbf{W}_{22}^{-1} \mathbf{W}_{21} \in \mathbb{R}^{(p-p_2) \times (p-p_2)}.$$

Entonces, si  $\boldsymbol{\Sigma}_{21} = \mathbf{0}$ , se cumple que

- $\mathbf{A} \sim \mathcal{W}(\boldsymbol{\Sigma}_{11}, p - p_2, p_2)$  y
- $\mathbf{A}$  es independiente de  $\mathbf{W}_{11.2}$  y  
 $\mathbf{W}_{11.2} \sim \mathcal{W}(\boldsymbol{\Sigma}_{11.2}, p - p_2, m - p_2) = \mathcal{W}(\boldsymbol{\Sigma}_{11}, p - p_2, m - p_2)$

## Teorema 1

Sean  $\mathbf{y} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$  con  $\boldsymbol{\Sigma} > 0$  y  $\mathbf{W} \sim \mathcal{W}(\boldsymbol{\Sigma}, p, m)$  independientes entre sí,  $m \geq p$ .

$$T_{2.1}^2 = (m - p_1) \frac{T_{p,m}^2 - T_{p_1,m}^2}{m + T_{p_1,m}^2}$$

a) Bajo  $H_0 : \lambda_p^2 = \lambda_{p_1}^2$  que es equivalente a  $H_0 : \boldsymbol{\mu}_{2.1} = 0$  se tiene

$$\frac{m - p + 1}{p - p_1} \frac{T_{2.1}^2}{m - p_1} = \frac{m - p + 1}{p - p_1} \frac{T_{p,m}^2 - T_{p_1,m}^2}{m + T_{p_1,m}^2} \sim \mathcal{F}_{p-p_1, m-p+1}$$

y  $T_{2.1}^2$  es independiente de  $T_{p_1}^2$

El factor  $m + T_{p_1,m}^2$  aparece pues la

$$\text{VAR}(\mathbf{y}_{2.1} \mid \mathbf{y}^{(1)}, \mathbf{W}_{11}) = \boldsymbol{\Sigma}_{22.1} (1 + T_{p_1,m}^2/m)$$

## Teorema 1

- b) Si  $\lambda_p^2 \neq \lambda_{p_1}^2$ , la distribución de  $T_{2.1}^2$  condicional a  $T_{p_1}^2$  es un Hotelling no central, o sea,

$$\frac{m-p+1}{p-p_1} \frac{T_{2.1}^2}{m-p_1} \Big|_{T_{p_1}^2} \sim \mathcal{F}_{p-p_1, m-p+1}(\nu)$$

con

$$\nu = \frac{\lambda_p^2 - \lambda_{p1}^2}{1 + \frac{T_{p1}}{m}}$$

## Observación

El estadístico anterior se aplicará cuando  $\mathbf{y} = \sqrt{n}\bar{\mathbf{x}} \sim N(\sqrt{n}\boldsymbol{\mu}, \boldsymbol{\Sigma})$  y  $\mathbf{W} = \mathbf{Q} \sim \mathcal{W}(\boldsymbol{\Sigma}, p, m)$ ,  $m = n - 1$ .

Supongamos que  $p_1 = p - 1$  luego  $p_2 = 1$ .

Por lo tanto

- $\mathbf{y}^{(2)} = \sqrt{n}\bar{x}_p$ ,
- $\mathbf{y}^{(1)} = \sqrt{n}\bar{\mathbf{x}}_{(p-1)} = \sqrt{n}(\bar{x}_1, \dots, \bar{x}_{p-1})^T$ .
- $\mathbf{W} = \mathbf{Q} = \begin{pmatrix} \mathbf{Q}_{(p-1,p-1)} & \mathbf{q}_{(p-1,p)} \\ \mathbf{q}_{(p-1,p)}^T & q_{pp} \end{pmatrix}$  con  $\mathbf{q}_{(p-1,p)} \in \mathbb{R}^{p-1}$
- $\mathbf{B} = \mathbf{q}_{(p-1,p)}^T \mathbf{Q}_{(p-1,p-1)}^{-1}$ ,  $\mathbf{B}^T \in \mathbb{R}^{p-1}$

Luego

$$T_{p,n-1}^2 - T_{p-1,n-1}^2 = (n-1) \mathbf{y}_{2.1}^T \mathbf{W}_{22.1}^{-1} \mathbf{y}_{2.1}$$

donde ahora

$$\mathbf{y}_{2.1} = \sqrt{n} (\bar{x}_p - \mathbf{B} \bar{\mathbf{x}}_{(p-1)})$$

$$\mathbf{W}_{22.1} = \mathbf{q}_{pp} - \mathbf{q}_{(p-1,p)}^T \mathbf{Q}_{(p-1,p-1)}^{-1} \mathbf{q}_{(p-1,p)} = (n-1) s_{p.(p-1)}$$

Es decir,

$$T_{p,n-1}^2 - T_{p-1,n-1}^2 = n \frac{(\bar{x}_p - \mathbf{B} \bar{\mathbf{x}}_{(p-1)})^2}{s_{p.(p-1)}} = T_{p|1,\dots,p-1}^2$$

Como

$$T_{p,n-1}^2 - T_{p-1,n-1}^2 = n \frac{(\bar{x}_p - \mathbf{B}\bar{\mathbf{x}}_{(p-1)})^2}{s_{p.(p-1)}} = T_{p|1,\dots,p-1}^2$$

obtenemos

$$T_{p,n-1}^2 = T_{p-1,n-1}^2 + n \frac{(\bar{x}_p - \mathbf{B}\bar{\mathbf{x}}_{(p-1)})^2}{s_{p.(p-1)}} = T_{p-1,n-1}^2 + T_{p|1,\dots,p-1}^2$$

que si se aplica sucesivamente sobre todas las variables da la descomposición de Mason, Young and Tracy (MYT) (1995, 1997, 1999) y permite entender el procedimiento Step down que daremos.

$$T_{p,n-1}^2 = T_{1,n-1}^2 + T_{2|1}^2 + T_{3|1,2}^2 + \cdots + T_{p-1|1,\dots,p-2}^2 + T_{p|1,\dots,p-1}^2$$

## Aplicación del test de Rao

Una aplicación del test de Rao es el método *step-down* para testear  $H_0 : \mu = \mathbf{0}$  basándonos en una muestra  $\mathbf{x}_1, \dots, \mathbf{x}_n$  i.i.d.,  $\mathbf{x}_i \in \mathbb{R}^p$ ,  $\mathbf{x}_i \sim N_p(\mu, \Sigma)$ ,  $\Sigma > 0$ ,  $n > p$ .

Sean

- $\mu_{(k)} = (\mu_1, \dots, \mu_k)^T$ ,  $k = 1, \dots, p$  y  $\mu_{(0)} = \mathbf{0}$ .
- $\mathbf{x}_{i,(k)} = (x_{i,1}, \dots, x_{i,k})^T$  o sea, consideramos las primeras  $k$  componentes de  $\mathbf{x}_i$ .
- $T_{0,(k)}^2 = n \bar{\mathbf{x}}_{(k)}^T \mathbf{S}_{(k)}^{-1} \bar{\mathbf{x}}_{(k)}$  el estadístico de Hotelling basado en  $\mathbf{x}_{1,(k)}, \dots, \mathbf{x}_{n,(k)}$  para testear  $\mu_{(k)} = \mathbf{0}$  donde

$$\bar{\mathbf{x}}_{(k)} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_{i,(k)} \quad \mathbf{S}_{(k)} = \frac{1}{n-1} \sum_{i=1}^n (\mathbf{x}_{i,(k)} - \bar{\mathbf{x}}_{(k)}) (\mathbf{x}_{i,(k)} - \bar{\mathbf{x}}_{(k)})^T$$

- Sea  $H_{0,k} : \mu_k - \beta_{(k-1)}\boldsymbol{\mu}_{(k-1)} = 0$
- Para  $k = 1, \dots, p$  definamos  $T_{0,(0)} = 0$  y

$$F_k = \frac{T_{0,(k)}^2 - T_{0,(k-1)}^2}{(n-1) + T_{0,(k-1)}^2} (n-k)$$

- $\beta_{(k-1)} = \sigma_{(k,k-1)}^T \boldsymbol{\Sigma}_{(k-1)}^{-1}$  con
  - ★  $\boldsymbol{\Sigma}_{(k)} = \text{VAR}(\mathbf{x}_{(k)})$
  - ★  $\sigma_{(k,k-1)} = \text{COV}(\mathbf{x}_k, \mathbf{x}_{(k-1)})$

Por el Teorema 1, si  $H_{0,k}$  es cierta,

- $F_k \sim \mathcal{F}_{1,n-k}$  y
- $F_k$  es independiente de  $T_{0,(k-1)}^2$ , más aún
- $F_k$  es independiente de  $\{F_j : j < k\}$ .



## Aplicación del test de Rao

$$H_{0,k} : \mu_k - \beta_{(k-1)} \mu_{(k-1)} = 0$$

Si  $\cap_{k=1}^{r-1} H_{0,k}$  es cierta, entonces

a)  $\mu_{(r-1)} = \mathbf{0}$

b) además,  $H_{0,r}$  será cierta si y sólo si  $\mu_r = 0$ .

Con lo cual  $H_0 : \mu = \mathbf{0}$  puede escribirse como

$$H_0 = \bigcap_{k=1}^p H_{0,k}$$

Es decir,  $H_0$  puede testearse sucesivamente con los estadísticos  $F_1, \dots, F_k$  en este orden.

$H_0$  se acepta si  $F_j < f_{1,n-j}(\alpha_j)$  para todo  $j = 1, \dots, p$ .

Luego el test tendrá nivel  $\alpha$  si

$$1 - \alpha = \prod_{k=1}^p (1 - \alpha_k)$$

Este test es un procedimiento alternativo al test de Hotelling que dimos antes y se usa si hay un orden a priori entre las medias  $\mu_k$ .

## Aplicación del test de Rao: Observaciones

Para que el test tenga nivel  $\alpha$  necesitamos que

$$1 - \alpha = \prod_{k=1}^p (1 - \alpha_k)$$

Supongamos que  $\alpha_1 = \dots = \alpha_k = \alpha_0$  entonces la condición es

$$1 - \alpha = (1 - \alpha_0)^p$$

de donde


$$\alpha_0 = 1 - (1 - \alpha)^{\frac{1}{p}}$$

p	$\alpha$		
	0.05	0.01	0.001
2	0.0253	0.0050	0.00050
4	0.0127	0.0025	0.00025
5	0.0102	0.0020	0.00020
10	0.0051	0.0010	0.00010

Valores de  $\alpha_0$



## Ejemplo



## Ejemplo

Queremos testear

$$H_0 : \mu = \mu_0$$

$$H_1 : \mu \neq \mu_0$$

con  $\mu_0 = (63.64, 1615.38)^T$ .

Haremos el test con todos los datos menos la observación  $(87, 1542)^T$  que es un dato atípico.

Tenemos que

$$T_0^2 = n(\bar{\mathbf{x}} - \mu_0)^T \mathbf{S}^{-1}(\bar{\mathbf{x}} - \mu_0) = 20.27881$$

y

$$F_0 = \frac{n-p}{p} \frac{T_0^2}{n-1} = 9.865$$

Como  $f_{2,36}(0.001) = 8.420$  rechazo con nivel  $\alpha = 0.001$ .

Más aún, el  $p$ -valor es 0.00038.



## Test de independencia entre $x_1$ y $(x_2, \dots, x_p)$

El coeficiente de correlación múltiple  $R_{1,2}$  es la máxima correlación posible entre la variable  $x_1$  y una combinación lineal  $\mathbf{a}^T \mathbf{x}^{(2)}$  del vector  $\mathbf{x}^{(2)}$ , donde  $\mathbf{x} = (x_1, \mathbf{x}^{(2)T})^T$ .


El test de cociente de máxima verosimilitud, bajo normalidad, estará basado en el coeficiente de correlación múltiple muestral  $\hat{R}_{1,2}$ .

Supongamos que  $\mathbf{x} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$  con  $\boldsymbol{\Sigma} > 0$ , particionemos a  $\mathbf{x}$ ,  $\boldsymbol{\mu}$ ,  $\boldsymbol{\Sigma}$  de la siguiente forma

$$\mathbf{x} = \begin{pmatrix} x_1 \\ \mathbf{x}^{(2)} \end{pmatrix} \quad \boldsymbol{\mu} = \begin{pmatrix} \mu_1 \\ \boldsymbol{\mu}^{(2)} \end{pmatrix}$$

$$\boldsymbol{\Sigma} = \begin{pmatrix} \sigma_{11} & \boldsymbol{\sigma}_{12} \\ \boldsymbol{\sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{pmatrix}$$





$$R_{1,2} = \max_{\mathbf{a} \neq 0} \frac{\text{COV}(x_1, \mathbf{a}^T \mathbf{x}^{(2)})}{(\text{VAR}(x_1) \text{VAR}(\mathbf{a}^T \mathbf{x}^{(2)}))^{\frac{1}{2}}} = \max_{\mathbf{a} \neq 0} \frac{\mathbf{a}^T \boldsymbol{\sigma}_{21}}{(\sigma_{11} \mathbf{a}^T \boldsymbol{\Sigma}_{22} \mathbf{a})^{\frac{1}{2}}}$$

Usando Cauchy-Schwartz se obtiene que

$$R_{1,2}^2 = \frac{\boldsymbol{\sigma}_{21}^T \boldsymbol{\Sigma}_{22}^{-1} \boldsymbol{\sigma}_{21}}{\sigma_{11}}$$

y se alcanza en

$$\mathbf{a}^T = \boldsymbol{\sigma}_{21}^T \boldsymbol{\Sigma}_{22}^{-1} = \boldsymbol{\sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1}$$

que era el coeficiente de la regresión de  $x_1$  en  $\mathbf{x}_2$  ya que

$$x_1 | \mathbf{x}^{(2)} = \mathbf{x}_0 \sim N \left( \mu_1 + \boldsymbol{\sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1} (\mathbf{x}_0 - \boldsymbol{\mu}^{(2)}), \boldsymbol{\Sigma}_{11.2} \right)$$

con  $\boldsymbol{\Sigma}_{11.2} = \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1} \boldsymbol{\Sigma}_{21} = 1/\sigma^{11}$ .

Queremos testear que  $x_1$  es independiente de  $(x_2, \dots, x_p)$  basados en una muestra  $\mathbf{x}_1, \dots, \mathbf{x}_n$  i.i.d.,  $\mathbf{x}_i \in \mathbb{R}^p$ ,  $\mathbf{x}_i \sim N_p(\mu, \Sigma)$ ,  $\Sigma > 0$ ,  $n > p$ .

$$H_0 : R_{1,2} = 0 \quad \text{o equivalentemente} \quad H_0 : \sigma_{21} = 0$$

El test de cociente de máxima verosimilitud rechaza si  $(1 - \hat{R}_{1,2}^2)^{n/2}$  es chico, donde

$$\hat{R}_{1,2}^2 = \frac{\mathbf{s}_{21}^T \mathbf{S}_{22}^{-1} \mathbf{s}_{21}}{s_{11}}$$

y

$$\mathbf{S} = \frac{1}{n-1} \mathbf{Q} = \begin{pmatrix} s_{11} & \mathbf{s}_{12} \\ \mathbf{s}_{21} & \mathbf{S}_{22} \end{pmatrix} = \begin{pmatrix} s_{11} & \mathbf{s}_{21}^T \\ \mathbf{s}_{21} & \mathbf{S}_{22} \end{pmatrix}$$

$$\hat{R}_{1,2}^2 = \frac{\mathbf{s}_{21}^T \mathbf{S}_{22}^{-1} \mathbf{s}_{21}}{s_{11}}$$

Ahora bien

$$\frac{\hat{R}_{1,2}^2}{1 - \hat{R}_{1,2}^2} = \frac{\mathbf{s}_{21}^T \mathbf{S}_{22}^{-1} \mathbf{s}_{21}}{s_{11.2}} = \frac{\mathbf{q}_{21}^T \mathbf{Q}_{22}^{-1} \mathbf{q}_{21}}{q_{11.2}}$$

con  $s_{11.2} = s_{11} - \mathbf{s}_{21}^T \mathbf{S}_{22}^{-1} \mathbf{s}_{21} = q_{11.2}/(n-1)$ .

Recordemos el Corolario 2 que enunciamos

## Corolario 2

Sea  $\mathbf{W} \sim \mathcal{W}(\Sigma, p, m)$  con  $m \geq p$  y  $\Sigma > 0$  y definamos  $\mathbf{A} = \mathbf{W}_{12} \mathbf{W}_{22}^{-1} \mathbf{W}_{21} \in \mathbb{R}^{(p-p_2) \times (p-p_2)}$ . Entonces, si  $\Sigma_{21} = \mathbf{0}$ , se cumple que

- $\mathbf{A} \sim \mathcal{W}(\Sigma_{11}, p - p_2, p_2)$  y
- $\mathbf{A}$  es independiente de  $\mathbf{W}_{11.2} \sim \mathcal{W}(\Sigma_{11}, p - p_2, m - p_2)$

Por lo tanto, como  $\mathbf{Q} \sim \mathcal{W}(\Sigma, p, n - 1)$ ,  $p_1 = 1$ ,  $p_2 = p - 1$  obtenemos que, bajo  $H_0 : \sigma_{21} = \mathbf{0}$

- $\mathbf{q}_{21}^T \mathbf{Q}_{22}^{-1} \mathbf{q}_{21} \sim \mathcal{W}(\sigma_{11}, 1, p - 1) = \sigma_{11} \chi_{p-1}^2$
- $\mathbf{q}_{21}^T \mathbf{Q}_{22}^{-1} \mathbf{q}_{21}$  es independiente de  $q_{11.2}$
- $q_{11.2} \sim \mathcal{W}(\Sigma_{11}, 1, (n - 1) - (p - 1)) = \sigma_{11} \chi_{n-p}^2$



## Test para el vector de coeficientes de regresión

De igual forma usando el Lema 1 podemos obtener un test para

$$H_{0,r} : \beta_r = \beta_{0,r}$$

donde  $\beta_{0,r} \in \mathbb{R}^{p_2}$  es un vector fijo y  $\mathbf{x} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$  con

$$\mathbf{x} = \begin{pmatrix} \mathbf{x}^{(1)} \\ \mathbf{x}^{(2)} \end{pmatrix} \quad \boldsymbol{\mu} = \begin{pmatrix} \boldsymbol{\mu}^{(1)} \\ \boldsymbol{\mu}^{(2)} \end{pmatrix}$$

$$\boldsymbol{\Sigma} = \begin{pmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{pmatrix} \quad \boldsymbol{\beta} = \boldsymbol{\Sigma}_{21} \boldsymbol{\Sigma}_{11}^{-1} = (\beta_1, \dots, \beta_{p_1}) \in \mathbb{R}^{p_2 \times p_1}$$

basándonos en la  $r$ -ésima columna de la matriz

$$\mathbf{B} = \mathbf{S}_{21} \mathbf{S}_{11}^{-1} = (\mathbf{b}_1, \dots, \mathbf{b}_{p_1})$$

# Test para el vector de coeficientes de regresión

Un test para  $H_0$  está dado por

$$\phi(\mathbf{X}) = \begin{cases} 1 & \text{si } \frac{T^2}{n-1-p_1} \frac{n-p}{p-p_1} > f_{p-p_1, n-p}(\alpha) \\ 0 & \text{si } \frac{T^2}{n-1-p_1} \frac{n-p}{p-p_1} \leq f_{p-p_1, n-p}(\alpha) \end{cases}$$

donde  $\mathbf{S}^{-1} = (s^{ij})$  y

$$T^2 = (n-1-p_1) \frac{1}{s_{rr}} (\mathbf{b}_r - \beta_{0,r})^T \mathbf{S}_{22.1}^{-1} (\mathbf{b}_r - \beta_{0,r})$$





ooooo  
 ooooooooooooo  
 ooooo

ooooooooo  
 o●o

oo  
 ooooo

ooooooooo  
 o

ooooooooo  
 oooo

## Test sobre la matriz $\Sigma$

Consideraremos los siguientes test sobre la matriz  $\Sigma$

- *Independencia de a bloques*, o sea

$$H_{01} : \Sigma_{ij} = 0 \quad 1 \leq i < j \leq k \quad \text{o sea} \quad H_0 : \Sigma = \text{diag}(\Sigma_{11}, \dots, \Sigma_{kk})$$

Es decir,  $x^{(1)}, \dots, x^{(k)}$  son independientes.

En particular,

★ si  $k = 2$ ,  $H_0 : \Sigma = \begin{pmatrix} \Sigma_{11} & 0 \\ 0 & \Sigma_{22} \end{pmatrix}$ , o sea  $x^{(1)}$  y  $x^{(2)}$  son independientes.

★ si  $k = 2$  y  $p_1 = 1$ , es el caso que consideramos anteriormente, tomando  $x^{(1)} = x_1$  y  $x^{(2)} = (x_2, \dots, x_p)^T$ .

★ si  $p_r = 1$  para todo  $1 \leq r \leq k$ , tenemos que  $H_0$  es equivalente a  $H_{01} : \Sigma = \text{diag}(\sigma_{11}, \dots, \sigma_{pp})$ .

## Test sobre la matriz $\Sigma$

- *Test de esfericidad* Nos interesa testear
  - $H_{02} : \Sigma = \sigma^2 \mathbf{I}_p$  con  $\sigma^2$  desconocido.
  - $H_{03} : \Sigma = \mathbf{I}_p$
- *Igualdad de bloques diagonales*  $H_{04} : \Sigma_{11} = \Sigma_{22} = \dots = \Sigma_{kk}$  cuando  $p_1 = p_2 = \dots = p_k = p_0$
- *Iguals correlaciones e iguales varianzas*

$$H_{05} : \Sigma = \sigma^2 \begin{pmatrix} 1 & \rho & \dots & \rho \\ \rho & 1 & \dots & \rho \\ \vdots & \vdots & \ddots & \vdots \\ \rho & \rho & \dots & 1 \end{pmatrix}$$

que es un supuesto que aparece en modelos mixtos o con mediciones repetidas.

## Criterio de Wilks

Tanto en el caso del test de independencia como en el modelo lineal multivariado es posible hallar dos matrices

- $\mathbf{U} \sim \mathcal{W}(\Sigma, p, N - r)$  y
- $\mathbf{H} \sim \mathcal{W}(\Sigma, p, r)$

independientes bajo la hipótesis nula de interés.

Más generalmente, tendremos

- $\mathbf{U} \sim \mathcal{W}(\Sigma, p, N - r)$  y
- $\mathbf{z}_j \sim N(\mu, \Sigma), 1 \leq j \leq r, \mathbf{H} = \sum_{j=1}^r \mathbf{z}_j \mathbf{z}_j^T$

donde muchas veces  $r < p$  pero  $N - r > p$ .

El estadístico de Wilks se utiliza para testear cualquier hipótesis equivalente a  $\mu = \mathbf{0}$ . Rechazaremos si el Wilks es pequeño.

## Criterio de Wilks

En analogía con el caso univariado Wilks (1932) definió el estadístico de Wilks.

**Definición** Sean  $\mathbf{U} \sim \mathcal{W}(\boldsymbol{\Sigma}, p, N - r)$  y  $\mathbf{z}_j \sim N(\mathbf{0}, \boldsymbol{\Sigma})$ ,  $1 \leq j \leq r$  independientes entre sí, el criterio de Wilks se define como

$$\Lambda(N, p, r) = \frac{|\mathbf{U}|}{|\mathbf{U} + \mathbf{H}|}$$

donde  $|\mathbf{A}|$  indica el determinante de la matriz  $\mathbf{A} \in \mathbb{R}^{p \times p}$  y  $\mathbf{H} = \sum_{j=1}^r \mathbf{z}_j \mathbf{z}_j^T \sim \mathcal{W}(\boldsymbol{\Sigma}, p, r)$

$N$ ,  $p$  y  $r$  son los parámetros del Wilks  $\Lambda$  y corresponden respectivamente a los grados de libertad de  $\mathbf{U} + \mathbf{H}$ , la dimensión de las matrices y los grados de libertad de  $\mathbf{H}$ .

Por otra parte, si  $\mathbf{U}$  es inversible  $\Lambda(N, p, r)$  depende sólo de los autovalores de  $\mathbf{H}\mathbf{U}^{-1}$ .

## Distribución del criterio de Wilks

a) Si  $r \geq p$ ,  $\mathbf{H} \sim \mathcal{W}(\mathbf{\Sigma}, p, r)$  tiene densidad y

$$\Lambda(N, p, r) \sim \prod_{j=1}^p b_{jj}^2$$

con  $b_{11}^2, \dots, b_{pp}^2$  son independientes  $b_{ii}^2 \sim \mathcal{B}\left(\frac{N-r+1-i}{2}, \frac{r}{2}\right)$

b) Si  $r < p$ ,

$$\Lambda(N, p, r) \sim \prod_{j=1}^r b_{jj}^2$$

con  $b_{11}^2, \dots, b_{rr}^2$  son independientes  $b_{ii}^2 \sim \mathcal{B}\left(\frac{N-p+1-i}{2}, \frac{p}{2}\right)$

Es decir,  $\Lambda(N, p, r) \sim \Lambda(N, r, p)$

ooooo  
 ooooooooooooo  
 oooo

ooooooooo  
 ooo

oo  
 o●ooo

oooooooo  
 o

ooooooooo  
 oooo

## Corolario

a) Si  $p = 1$ ,

$$\frac{1 - \Lambda(N, 1, r)}{\Lambda(N, 1, r)} \frac{N - r}{r} \sim \mathcal{F}_{r, N-r}$$

b) Si  $r = 1$ ,

$$\frac{1 - \Lambda(N, p, 1)}{\Lambda(N, p, 1)} \frac{N - p}{p} \sim \mathcal{F}_{p, N-p}$$

c) Si  $p = 2$ ,

$$\frac{1 - \Lambda(N, 2, r)^{\frac{1}{2}}}{\Lambda(N, 2, r)^{\frac{1}{2}}} \frac{N - r - 1}{r} \sim \mathcal{F}_{2r, 2(N-r-1)}$$

d) Si  $r = 2$ ,

$$\frac{1 - \Lambda(N, p, 2)^{\frac{1}{2}}}{\Lambda(N, p, 2)^{\frac{1}{2}}} \frac{N - p - 1}{p} \sim \mathcal{F}_{2p, 2(N-p-1)}$$

## Aproximaciones a la Distribución del criterio de Wilks

a) Barlett (1938) mostró que

$$\mathbb{P}(-f \log(\Lambda(N, p, r)) > C_\alpha \chi_{pr, \alpha}^2) \approx \alpha$$

donde

$$f = N - r - \frac{1}{2}(p - r + 1) = N - \frac{1}{2}(p + r + 1)$$

Los valores  $C_\alpha$  para esta aproximación están en el Apéndice D13 de Seber (1984).

b) Rao (1951) mostró que

$$\frac{(fs + 2\lambda)}{2m} \frac{(1 - \Lambda(N, p, r)^{\frac{1}{s}})}{\Lambda(N, p, r)^{\frac{1}{s}}} \approx \mathcal{F}_{2m, fs+2\lambda}$$

donde  $f = N - (p + r + 1)/2$

$$m = \frac{pr}{2} \quad \lambda = -\frac{(pr - 2)}{4} \quad s = \frac{(p^2 r^2 - 4)^{\frac{1}{2}}}{(p^2 + r^2 - 5)^{\frac{1}{2}}}$$

## Otros criterios

Supongamos que  $\mathbf{U}$  es inversible y sean  $\lambda_1 \geq \dots \geq \lambda_p$  los autovalores de  $\mathbf{H}\mathbf{U}^{-1}$ .

$$\Lambda(N, p, r) = \frac{1}{\prod_{j=1}^p (1 + \lambda_j)}$$

Hay otros criterios que se utilizan

### a) Criterio de Lawley Hotelling

$$\text{tr}(\mathbf{H}\mathbf{U}^{-1}) = \sum_{j=1}^p \lambda_j$$

Los percentiles de la distribución de este estadístico están dados en el Apéndice D15 de Seber (1984).



## Otros criterios

### b) Criterio de Pillai

$$\text{tr}(\mathbf{H}(\mathbf{U} + \mathbf{H})^{-1}) = \sum_{j=1}^p \frac{\lambda_j}{1 + \lambda_j}$$

Los percentiles de la distribución de este estadístico están dados en el Apéndice D16 de Seber (1984).

c) **Criterio de Roy** o de la máxima raíz. Considera la máxima raíz  $\theta_{\max}$  de  $|\mathbf{H} - \theta(\mathbf{U} + \mathbf{H})| = 0$ . Luego

$$\theta_{\max} = \frac{\lambda_1}{1 + \lambda_1}$$

y rechazo si  $\theta_{\max}$  es grande. Los percentiles de la distribución de  $\theta_{\max}$  están dados en el Apéndice D14 de Seber (1984).

Si  $r = 1$ , todos los criterios son equivalentes, en particular, tenemos que  $\Lambda(N, p, r) = 1 - \theta_{\max}$ .

## Test de Independencia $H_{01}$

Dada muestra  $\mathbf{x}_1, \dots, \mathbf{x}_n$  i.i.d.,  $\mathbf{x}_i \in \mathbb{R}^p$ ,  $\mathbf{x}_i \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ ,  $\boldsymbol{\Sigma} > 0$ ,  $n > p$ . Particionemos a  $\mathbf{x}_i$ ,  $\boldsymbol{\mu}$ ,  $\bar{\mathbf{x}}$ ,  $\boldsymbol{\Sigma}$  y a  $\mathbf{Q} = (n-1)\mathbf{S}$  como

$$\mathbf{x}_i = \begin{pmatrix} \mathbf{x}_{i1} \\ \vdots \\ \mathbf{x}_{ik} \end{pmatrix}$$

$$\boldsymbol{\mu} = \begin{pmatrix} \boldsymbol{\mu}_1 \\ \vdots \\ \boldsymbol{\mu}_k \end{pmatrix} \quad \bar{\mathbf{x}} = \begin{pmatrix} \bar{\mathbf{x}}_1 \\ \vdots \\ \bar{\mathbf{x}}_k \end{pmatrix}$$

$$\boldsymbol{\Sigma} = \begin{pmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} & \dots & \boldsymbol{\Sigma}_{1k} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} & \dots & \boldsymbol{\Sigma}_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ \boldsymbol{\Sigma}_{k1} & \boldsymbol{\Sigma}_{k2} & \dots & \boldsymbol{\Sigma}_{kk} \end{pmatrix}$$

$$\mathbf{Q} = \begin{pmatrix} \mathbf{Q}_{11} & \mathbf{Q}_{12} & \dots & \mathbf{Q}_{1k} \\ \mathbf{Q}_{21} & \mathbf{Q}_{22} & \dots & \mathbf{Q}_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{Q}_{k1} & \mathbf{Q}_{k2} & \dots & \mathbf{Q}_{kk} \end{pmatrix}$$

donde  $\boldsymbol{\mu}_r \in \mathbb{R}^{p_r}$  y  $\boldsymbol{\Sigma}_{rr} \in \mathbb{R}^{p_r \times p_r}$ .

Observemos que si  $n > p$ ,  $\mathbb{P}(\mathbf{Q} > 0) = 1$  luego  $\mathbb{P}(\mathbf{Q}_{jj} > 0) = 1$ ,  $j = 1, \dots, k$ .

## Test de Independencia $H_{01} : \Sigma = \text{diag}(\Sigma_{11}, \dots, \Sigma_{kk})$

El test de cociente de máxima verosimilitud para  $H_0$  está basado en

$$\gamma^* = \left( \frac{|\mathbf{Q}|}{\prod_{j=1}^k |\mathbf{Q}_{jj}|} \right)^{\frac{n}{2}}$$

donde  $-2 \log(\gamma^*) \xrightarrow{D} \chi^2_\nu$  con  $\nu = \frac{1}{2} (p^2 - \sum_{j=1}^k p_j^2)$ .

Por lo tanto, el test será

$$\phi(\mathbf{X}) = \begin{cases} 1 & \text{si } \frac{|\mathbf{Q}|}{\prod_{j=1}^k |\mathbf{Q}_{jj}|} \leq k_\alpha \\ 0 & \text{si } \frac{|\mathbf{Q}|}{\prod_{j=1}^k |\mathbf{Q}_{jj}|} > k_\alpha \end{cases}$$

donde para tener un test de nivel asintótico  $\alpha$ ,

$$k_\alpha = \exp \left\{ -\frac{1}{n} \chi^2_{\nu, \alpha} \right\}$$

## Test de Independencia $H_{01} : \Sigma = \text{diag}(\Sigma_{11}, \dots, \Sigma_{kk})$

En particular, si  $k = p$ ,  $H_{01} : \Sigma = \text{diag}(\sigma_{11}, \dots, \sigma_{pp})$ , estamos testeando la independencia de las  $p$  variables.

El test de cociente de máxima verosimilitud para  $H_{01}$  está basado en

$$\gamma = \frac{|\mathbf{Q}|}{\prod_{j=1}^p |q_{jj}|} = |\mathbf{R}|$$

donde

$$\mathbf{R} = \text{diag} \left( s_{11}^{-\frac{1}{2}}, \dots, s_{pp}^{-\frac{1}{2}} \right) \mathbf{S} \text{diag} \left( s_{11}^{-\frac{1}{2}}, \dots, s_{pp}^{-\frac{1}{2}} \right)$$

es la matriz de correlación muestral.

En este caso,

$$-n \log(|\mathbf{R}|) \xrightarrow{D} \chi_{\nu}^2 \quad \text{con} \quad \nu = \frac{p(p-1)}{2}$$

## Test de Independencia $H_{01} : \Sigma = \text{diag}(\Sigma_{11}, \Sigma_{22})$

Si  $k = 2$ , estamos testeando  $\Sigma_{12} = 0$ .

El test de cociente de máxima verosimilitud para  $H_0$  está basado en

$$\gamma = \frac{|\mathbf{Q}|}{|\mathbf{Q}_{11}| |\mathbf{Q}_{22}|}.$$

Pero

$$\begin{aligned} |\mathbf{Q}| &= |\mathbf{Q}_{11}| |\mathbf{Q}_{22} - \mathbf{Q}_{21} \mathbf{Q}_{11}^{-1} \mathbf{Q}_{12}| = |\mathbf{Q}_{11}| |\mathbf{Q}_{22.1}| \\ &= |\mathbf{Q}_{11}| |\mathbf{Q}_{22}| |\mathbf{I}_{p_2} - \mathbf{Q}_{22}^{-1} \mathbf{Q}_{21} \mathbf{Q}_{11}^{-1} \mathbf{Q}_{12}| \end{aligned}$$

con lo cual

$$\gamma = |\mathbf{I}_{p_2} - \mathbf{Q}_{21} \mathbf{Q}_{11}^{-1} \mathbf{Q}_{12} \mathbf{Q}_{22}^{-1}| = \prod_{j=1}^s (1 - r_j^2)$$

donde  $s = \min(p_1, p_2)$  y  $r_j^2$  son los autovalores de  $\mathbf{Q}_{21} \mathbf{Q}_{11}^{-1} \mathbf{Q}_{12} \mathbf{Q}_{22}^{-1}$ .

Test de Independencia  $H_{01} : \Sigma = \text{diag}(\Sigma_{11}, \Sigma_{22})$

Por otra parte,

$$\gamma = \frac{|\mathbf{Q}_{22.1}|}{|\mathbf{Q}_{22}|} = \frac{|\mathbf{U}|}{|\mathbf{U} + \mathbf{H}|}$$

Ahora bien,

- $\mathbf{U} = \mathbf{Q}_{22.1} \sim \mathcal{W}(\mathbf{\Sigma}_{22.1}, p_2, n-1-p_1) = \mathcal{W}(\mathbf{\Sigma}_{22}, p_2, n-1-p_1)$  bajo  $H_{01}$
- $\mathbf{H} = \mathbf{Q}_{21} \mathbf{Q}_{11}^{-1} \mathbf{Q}_{12} \sim \mathcal{W}(\mathbf{\Sigma}_{22.1}, p_2, p_1) = \mathcal{W}(\mathbf{\Sigma}_{22}, p_2, p_1)$  bajo  $H_{01}$
- $\mathbf{H}$  y  $\mathbf{U}$  son independientes bajo  $H_{01}$ .

Luego,

$$\gamma = \Lambda(n-1, p_1, p_2)$$

Test de Independencia  $H_{01} : \Sigma = \text{diag}(\Sigma_{11}, \Sigma_{22})$

Queremos aplicar el principio de unión intersección de Roy para testear  $H_{01} : \mathbf{\Sigma}_{12} = 0$ .

Recordemos que

$$\mathbf{x}_i = \begin{pmatrix} \mathbf{x}_{i1} \\ \mathbf{x}_{i2} \end{pmatrix}$$

entonces  $\text{Cov}(\mathbf{a}^T \mathbf{x}_{11}, \mathbf{b}^T \mathbf{x}_{12}) = \mathbf{a}^T \boldsymbol{\Sigma}_{12} \mathbf{b}$ . Definamos

$$H_{0,\text{ab}} : \mathbf{a}^T \mathbf{\Sigma}_{12} \mathbf{b} = 0$$

Luego

$$H_{01} = \cap_{\mathbf{a} \neq \mathbf{0}} \cap_{\mathbf{b} \neq \mathbf{0}} H_{0,\mathbf{ab}}$$

Test de Independencia  $H_{01} : \Sigma = \text{diag}(\Sigma_{11}, \Sigma_{22})$

Aplicando el principio de unión intersección, se obtiene el criterio de Roy.

Es decir, el test rechaza si

$$\theta_{\max} > k_{\alpha}$$

donde  $\theta_{\max}$  es la máxima raíz de  $|\mathbf{H} - \theta(\mathbf{U} + \mathbf{H})| = 0$ , o sea,  $\theta_{\max}$  es el máximo autovalor de  $\mathbf{Q}_{21}\mathbf{Q}_{11}^{-1}\mathbf{Q}_{12}\mathbf{Q}_{22}^{-1}$ .



## Test de esfericidad $H_{02} : \Sigma = \sigma^2 \mathbf{I}_p, \sigma^2 > 0$

El test de cociente de máxima verosimilitud para  $H_{02}$  está basado en

$$\gamma^* = \left( \frac{|\mathbf{Q}|^{\frac{1}{p}}}{\frac{1}{p} \text{tr}(\mathbf{Q})} \right)^{\frac{np}{2}}$$

donde  $-2 \log(\gamma^*) \xrightarrow{D} \chi^2_\nu$  con  $\nu = \frac{p(p+1)}{2} - 1$ . Por lo tanto, el test será

$$\phi(\mathbf{X}) = \begin{cases} 1 & \text{si } \frac{|\mathbf{Q}|^{\frac{1}{p}}}{\frac{1}{p} \text{tr}(\mathbf{Q})} \leq k_\alpha \\ 0 & \text{si } \frac{|\mathbf{Q}|^{\frac{1}{p}}}{\frac{1}{p} \text{tr}(\mathbf{Q})} > k_\alpha \end{cases}$$

donde para tener un test de nivel asintótico  $\alpha$ ,

$$k_\alpha = \exp \left\{ -\frac{1}{np} \chi^2_{\nu, \alpha} \right\}$$



## Test para varias muestras

$$\mathbf{Q}_i = \sum_{j=1}^{n_i} (\mathbf{x}_{i,j} - \bar{\mathbf{x}}_i)(\mathbf{x}_{i,j} - \bar{\mathbf{x}}_i)^T \quad \hat{\Sigma}_i = \frac{\mathbf{Q}_i}{n_i} \quad \bar{\mathbf{x}}_i = \frac{1}{n_i} \sum_{j=1}^{n_i} \mathbf{x}_{i,j}$$

La suma de cuadrados dentro de grupos es

$$\mathbf{U} = \mathbf{Q}_1 + \cdots + \mathbf{Q}_k = \sum_{i=1}^k \sum_{j=1}^{n_i} (\mathbf{x}_{i,j} - \bar{\mathbf{x}}_i)(\mathbf{x}_{i,j} - \bar{\mathbf{x}}_i)^T$$

Tenemos que

- $\mathbf{Q}_i \sim \mathcal{W}(\Sigma_i, p, n_i - 1)$
- $\mathbf{Q}_1, \dots, \mathbf{Q}_k$  son independientes.

Luego, bajo  $H_1 : \Sigma_1 = \cdots = \Sigma_k$ ,  $\mathbf{U} \sim \mathcal{W}(\Sigma, p, n - k)$  con  $n = \sum_{i=1}^k n_i$ .

## Test para varias muestras

Por otra parte, sea  $\mathbf{H}$  la suma de cuadrados entre poblaciones.

$$\mathbf{H} = \sum_{i=1}^k n_i (\bar{\mathbf{x}}_i - \bar{\mathbf{x}})(\bar{\mathbf{x}}_i - \bar{\mathbf{x}})^T$$

donde

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^k n_i \bar{\mathbf{x}}_i$$

Veremos que bajo  $H_3$

- $\mathbf{H} \sim \mathcal{W}(\Sigma, p, k - 1)$
- $\mathbf{H}$  es independiente de  $\mathbf{U}$ .

## Teorema

Sean  $\nu = pk + \frac{p(p+1)}{2}k$ ,  $\nu_1 = pk + \frac{p(p+1)}{2}$  y  $\nu_2 = p + \frac{p(p+1)}{2}$ .

a) El criterio de cociente de verosimilitud para  $H_1 : \Sigma_1 = \dots = \Sigma_k$ , se basa en

$$\gamma_1^* = \frac{\prod_{j=1}^k \left| \frac{\mathbf{Q}_j}{n_j} \right|^{\frac{n_j}{2}}}{\left| \frac{\mathbf{U}}{n} \right|^{\frac{n}{2}}}$$

Rechazo si  $\gamma_1^* < k_{1,\alpha}$ .

Además, bajo  $H_1$ , se tiene que  $-2 \log(\gamma_1^*) \xrightarrow{D} \chi_{\nu-\nu_1}^2$

## Teorema

b) El criterio de cociente de verosimilitud para

$$H_2 : \mu_1 = \cdots = \mu_k, \Sigma_1 = \cdots = \Sigma_k$$

$$\gamma_2^* = \frac{\prod_{j=1}^k \left| \frac{\mathbf{Q}_j}{n_j} \right|^{\frac{n_j}{2}}}{\left| \frac{\mathbf{U} + \mathbf{H}}{n} \right|^{\frac{n}{2}}}$$

Rechazo si  $\gamma_2^* < k_{2,\alpha}$ .

Además, bajo  $H_2$ , se tiene que  $-2 \log(\gamma_2^*) \xrightarrow{D} \chi_{\nu-\nu_2}^2$

## Teorema

- c) El criterio de cociente de verosimilitud para  $H_3 : \mu_1 = \cdots = \mu_k$  cuando  $\Sigma_1 = \cdots = \Sigma_k$

$$\gamma_3^* = \left( \frac{|\mathbf{U}|}{|\mathbf{U} + \mathbf{H}|} \right)^{\frac{n}{2}}$$

Rechazo si  $\gamma_3^* < k_{3,\alpha}$ .

Además, bajo  $H_3$ , se tiene que  $-2 \log(\gamma_3^*) \xrightarrow{D} \chi_{\nu_1 - \nu_2}^2$ . Más aún, bajo  $H_3$ ,  $\mathbf{U} \sim \mathcal{W}(\Sigma, p, n - k)$ ,  $\mathbf{H} \sim \mathcal{W}(\Sigma, p, k - 1)$  independientes de donde

$$\gamma_3^{*\frac{2}{n}} = \frac{|\mathbf{U}|}{|\mathbf{U} + \mathbf{H}|} = \Lambda(n - 1, p, k - 1)$$

Observemos que  $\text{rango}(\mathbf{U}) = \min(p, n - k)$  y  $\text{rango}(\mathbf{H}) = \min(p, k - 1)$ .

Si  $k = 2$ ,  $\text{rango}(\mathbf{H}) = 1$  y obtenemos el test de Hotelling para dos muestras.

## Propiedad

Sea  $\mathbf{x} \in \mathbb{R}^p$  un vector aleatorio y  $G$  una variable aleatoria que indica la pertenencia al grupo, tales que para  $1 \leq j \leq k$

$$\mathbb{P}(G = j) = \pi_j \quad \mathbb{E}(\mathbf{x}|G = j) = \boldsymbol{\mu}_j \quad \text{VAR}(\mathbf{x}|G = j) = \boldsymbol{\Sigma}_j$$

entonces si  $\bar{\boldsymbol{\mu}} = \mathbb{E}(\mathbf{x})$  y  $\bar{\boldsymbol{\Sigma}} = \text{VAR}(\mathbf{x})$  se cumple que

$$\bar{\boldsymbol{\mu}} = \sum_{j=1}^k \pi_j \boldsymbol{\mu}_j \quad \bar{\boldsymbol{\Sigma}} = \boldsymbol{\Sigma}_W + \boldsymbol{\Sigma}_B$$

donde

$$\boldsymbol{\Sigma}_W = \sum_{j=1}^k \pi_j \boldsymbol{\Sigma}_j \quad \boldsymbol{\Sigma}_B = \sum_{j=1}^k \pi_j (\boldsymbol{\mu}_j - \bar{\boldsymbol{\mu}})(\boldsymbol{\mu}_j - \bar{\boldsymbol{\mu}})^T$$



Por lo tanto, si  $\Sigma_j = \Sigma$  para  $1 \leq j \leq k$  tenemos que

- $\Sigma_W = \sum_{j=1}^k \pi_j \Sigma_j = \Sigma$  mide la variabilidad dentro de grupos
- $\Sigma_B$  mide la variabilidad entre grupos.

Es decir, descompusimos

**la variabilidad total como la variabilidad dentro de grupos más la variabilidad entre grupos.**

Observemos que

- $\Sigma_B$  es definida no-negativa de rango  $s \leq \min(k-1, p)$ .
- Bajo  $H_3$ ,  $\Sigma_B = 0$

Luego, tenemos que

$$\bar{\Sigma} \geq \Sigma_W \quad \text{y bajo } H_3 \quad \bar{\Sigma} = \Sigma_W$$

o sea, para realizar un test para  $H_3$  basta comparar cuan distinta es  $\bar{\Sigma}$  de  $\Sigma_W$ .

Por otra parte, si las poblaciones son normales  $\hat{\Sigma}_j = \mathbf{Q}_j/n_j$  es el EMV de  $\Sigma_j$  y  $\bar{\mathbf{x}}_j$  es el de  $\mu_j$ . Luego, si  $\hat{\pi}_j = n_j/n$

$$\hat{\bar{\mu}} = \sum_{j=1}^k \hat{\pi}_j \hat{\mu}_j \quad \hat{\bar{\Sigma}} = \hat{\Sigma}_W + \hat{\Sigma}_B$$

son los EMV de  $\bar{\mu}$  y  $\bar{\Sigma}$ , donde

$$\hat{\Sigma}_W = \sum_{j=1}^k \hat{\pi}_j \hat{\Sigma}_j \quad \hat{\Sigma}_B = \sum_{j=1}^k \hat{\pi}_j (\hat{\mu}_j - \hat{\bar{\mu}})(\hat{\mu}_j - \hat{\bar{\mu}})^T$$

O sea,

- $\mathbf{U}/n$  es el EMV de  $\Sigma_W$ ,
- $\mathbf{H}/n$  es el EMV de  $\Sigma_B$  y
- $(\mathbf{U} + \mathbf{H})/n$  es el EMV de  $\bar{\Sigma}$ ,

lo que explica el estadístico del test para  $H_3$ .

## Ejemplo

Variables medidas sobre árboles de manzana de 6 injertos. Para cada injerto hay 8 árboles. Las variables son:

$x_1$  =Diámetro del tronco a los 4 años en unidades de 10cm,

$x_2$  =Largo a los 4 años,

$x_3$  =Diámetro del tronco a los 15 años en unidades de 10cm,

$x_4$  =Peso del árbol a los 15 años, en unidades de 1000 libras.

Inj.	1	1	1	1	1	1	1	1	2	2	2	2
$x_1$	1.11	1.19	1.09	1.25	1.11	1.08	1.11	1.16	1.05	1.17	1.11	1.25
$x_2$	2.569	2.928	2.865	3.844	3.027	2.336	3.211	3.037	2.074	2.885	3.378	3.906
$x_3$	3.58	3.75	3.93	3.94	3.60	3.51	3.98	3.62	4.09	4.06	4.87	4.98
$x_4$	0.760	0.821	0.928	1.009	0.766	0.726	1.209	0.750	1.036	1.094	1.635	1.517
Inj.	2	2	2	2	3	3	3	3	3	3	3	3
$x_1$	1.17	1.15	1.17	1.19	1.07	0.99	1.06	1.02	1.15	1.20	1.20	1.17
$x_2$	2.782	3.018	3.383	3.447	2.505	2.315	2.667	2.390	3.021	3.085	3.308	3.231
$x_3$	4.38	4.65	4.69	4.40	3.76	4.44	4.38	4.67	4.48	4.78	4.57	4.56
$x_4$	1.197	1.244	1.495	1.026	0.912	1.398	1.197	1.613	1.476	1.571	1.506	1.458
Inj.	4	4	4	4	4	4	4	4	5	5	5	5
$x_1$	1.22	1.03	1.14	1.01	0.99	1.11	1.20	1.08	0.91	1.15	1.14	1.05
$x_2$	2.838	2.351	3.001	2.439	2.199	3.318	3.601	3.291	1.532	2.552	3.083	2.330
$x_3$	3.89	4.05	4.05	3.92	3.27	3.95	4.27	3.85	4.04	4.16	4.79	4.42
$x_4$	0.944	1.241	1.023	1.067	0.693	1.085	1.242	1.017	1.084	1.151	1.381	1.242
Inj.	5	5	5	5	6	6	6	6	6	6	6	6
$x_1$	0.99	1.22	1.05	1.13	1.11	0.75	1.05	1.02	1.05	1.07	1.13	1.11
$x_2$	2.079	3.366	2.416	3.100	2.813	0.840	2.199	2.132	1.949	2.251	3.064	2.469
$x_3$	3.47	4.41	4.64	4.57	3.76	3.14	3.75	3.99	3.34	3.21	3.63	3.95
$x_4$	0.673	1.137	1.455	1.325	0.800	0.606	0.790	0.853	0.610	0.562	0.707	0.952

## Ejemplo

Se desea estudiar si las medias de los distintos injertos son iguales. Nosotros consideraremos solamente los Injertos 1, 2 y 3.

Primero estudiaremos si las poblaciones correspondientes a los 3 injertos tienen iguales matrices de covarianza, o sea, testaremos

$$H_1 : \Sigma_1 = \Sigma_2 = \Sigma_3$$

A continuación se dan las matrices de covarianza estimadas

$$s_1 = \begin{pmatrix} 0.0034 & 0.0203 & 0.0037 & 0.0018 \\ 0.0203 & 0.2007 & 0.0580 & 0.0458 \\ 0.0037 & 0.0580 & 0.0352 & 0.0285 \\ 0.0018 & 0.0458 & 0.0285 & 0.0283 \end{pmatrix} \quad s_2 = \begin{pmatrix} 0.0034 & 0.0258 & 0.0088 & 0.0032 \\ 0.0258 & 0.3048 & 0.1498 & 0.0832 \\ 0.0088 & 0.1498 & 0.1157 & 0.0711 \\ 0.0032 & 0.0832 & 0.0711 & 0.0565 \end{pmatrix}$$

$$s_3 = \begin{pmatrix} 0.0068 & 0.0314 & 0.0087 & 0.0060 \\ 0.0314 & 0.1543 & 0.0480 & 0.0329 \\ 0.0087 & 0.0480 & 0.0951 & 0.0680 \\ 0.0060 & 0.0329 & 0.0680 & 0.0534 \end{pmatrix}$$

con lo cual  $-2 \log(\gamma_1^*) = 25.80706$  y  $\chi_{0.99,20}^2 = 37.56623$ .

No rechazamos  $H_1$  y el  $p$ -valor es 0.1723.

## Ejemplo

Supongamos entonces que las poblaciones correspondientes a los injertos 1, 2 y 3 tienen la misma matriz de covarianza y estudiemos si las medias son iguales, o sea, queremos testear  $H_3$ .

El estadístico del test es

$$V = \gamma_3^{\star \frac{2}{n}} = \frac{|\mathbf{U}|}{|\mathbf{U} + \mathbf{H}|} = \Lambda(n-1, p, k-1)$$

En nuestro caso,  $p = 4$ ,  $k = 3$  y  $n = 24$ . Hemos visto que

$$\frac{1 - \Lambda(N, p, 2)^{\frac{1}{2}}}{\Lambda(N, p, 2)^{\frac{1}{2}}} \frac{N - p - 1}{p} \sim \mathcal{F}_{2p, 2(N-p-1)}$$

Luego, rechazaremos  $H_3$  si

$$\frac{1 - V^{\frac{1}{2}}}{V^{\frac{1}{2}}} \frac{(n-1) - p - 1}{p} > f_{2p, 2(n-p-2)}(\alpha)$$

## Ejemplo

En el ejemplo que nos interesa  $V = 0.1447022$ ,  $n - p - 2 = 18$  luego  $f_{8,36}(0.01) = 3.051726$  y

$$\frac{1 - V^{\frac{1}{2}}}{V^{\frac{1}{2}}} = 7.329734$$

con lo que rechazamos  $H_3$  y el  $p$ -valor es  $10^{-5}$ .